

Artificial Intelligence

8.不确定知识与推理b

对应课本13-15章

贝叶斯网络

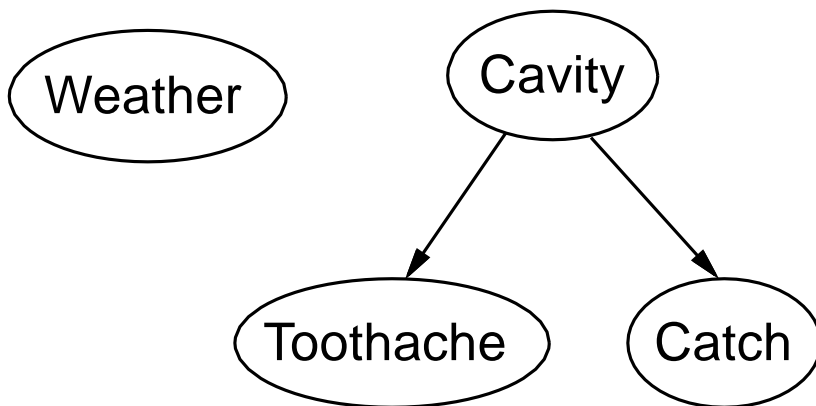
- 语法
- 语义
- 参数化分布

贝叶斯网络

- 贝叶斯网络是由简单的、图形化的符号组成，用于做条件独立的推理，因此其比完整的联合分布表示更为紧凑
- 语法表示：
 - 一组节点，每个变量一个
 - 有向无环图（链接 \approx “直接影响”）
 - 给定每个节点的父节点的条件分布 $P(X_i | Parents(X_i))$
- 在最简单的情况下，条件分布表示为条件概率表(CPT)，给出每个父值组合的 X_i 上的分布

例子

- 网络拓扑编码条件独立性断言：



- Weather* 相对其它变量是独立的
- Toothache* 和 *Catch* 和给定的 *Cavity* 是条件独立

家庭报警器

0

分享到

分享

收藏

所以其实美国西部的 House，和中国不一样，这里没有高楼大厦，建筑扁扁平平宽度很大，甚至越有钱的人越住在荒不溜秋的山上，偶尔有野生动物爬进院子，一点都不奇怪。这也带来一个问题：美国人怎么管理住房安全？

就以我上个月住朋友家的经历为例，请看下面指示图，它是装在家门口的一个白色机器：



如果睡得早，通常我会在凌晨五点半去星巴克。出门前，我先要在这个机器中间的“键盘”处，按几个数字键。这是一串由女主人自设的密码，如果不按就出门，随即家里会警报大作，因为我已经动了门窗，它会假设你是不知密码的外来闯入者。

初到朋友家时，我曾在地下室推开落地窗走到大山坡，马上就被楼上朋友知道了。“你去干嘛啦？”“我去看鸵鸟了。”所以任何门窗有动静，我朋友即使坐客厅一动不动，也能知道具体是哪个部位发生异常。

但按完“数字键”还没完，我还要按数字键上面左边的“Doors+Windows”，这表示：我在解锁、开门后，再把门窗锁上，因为我要让房子重新处于一个被 Home Security System 监控状态。

亲历美国家庭智能安防

sohu.com/a/2302542_120497

新闻 体育 汽车 房产 旅游 教育 时尚 科技 财经 娱乐 更多

登录

美国不卖中国手机芯片，谷歌不再提供安...

杀伤力太大了！特朗普突然下狠手，直接针...

雅戈尔 YOUNGOR

太值啦

买1送2

大牌热卖>

24小时热文

1

四十年来科技创新，康佳致力连接美好

2.1万 阅读

2

搜狐新社交产品，疫情宅家太无聊？帅哥美女等你撩

170万 阅读

3

任正非的痛：炒了十几年房地产，救活不了一张国产芯片

11万 阅读

罗永浩5.20“卖花”翻车，背后的“花点时间”获高圆圆...

9万 阅读

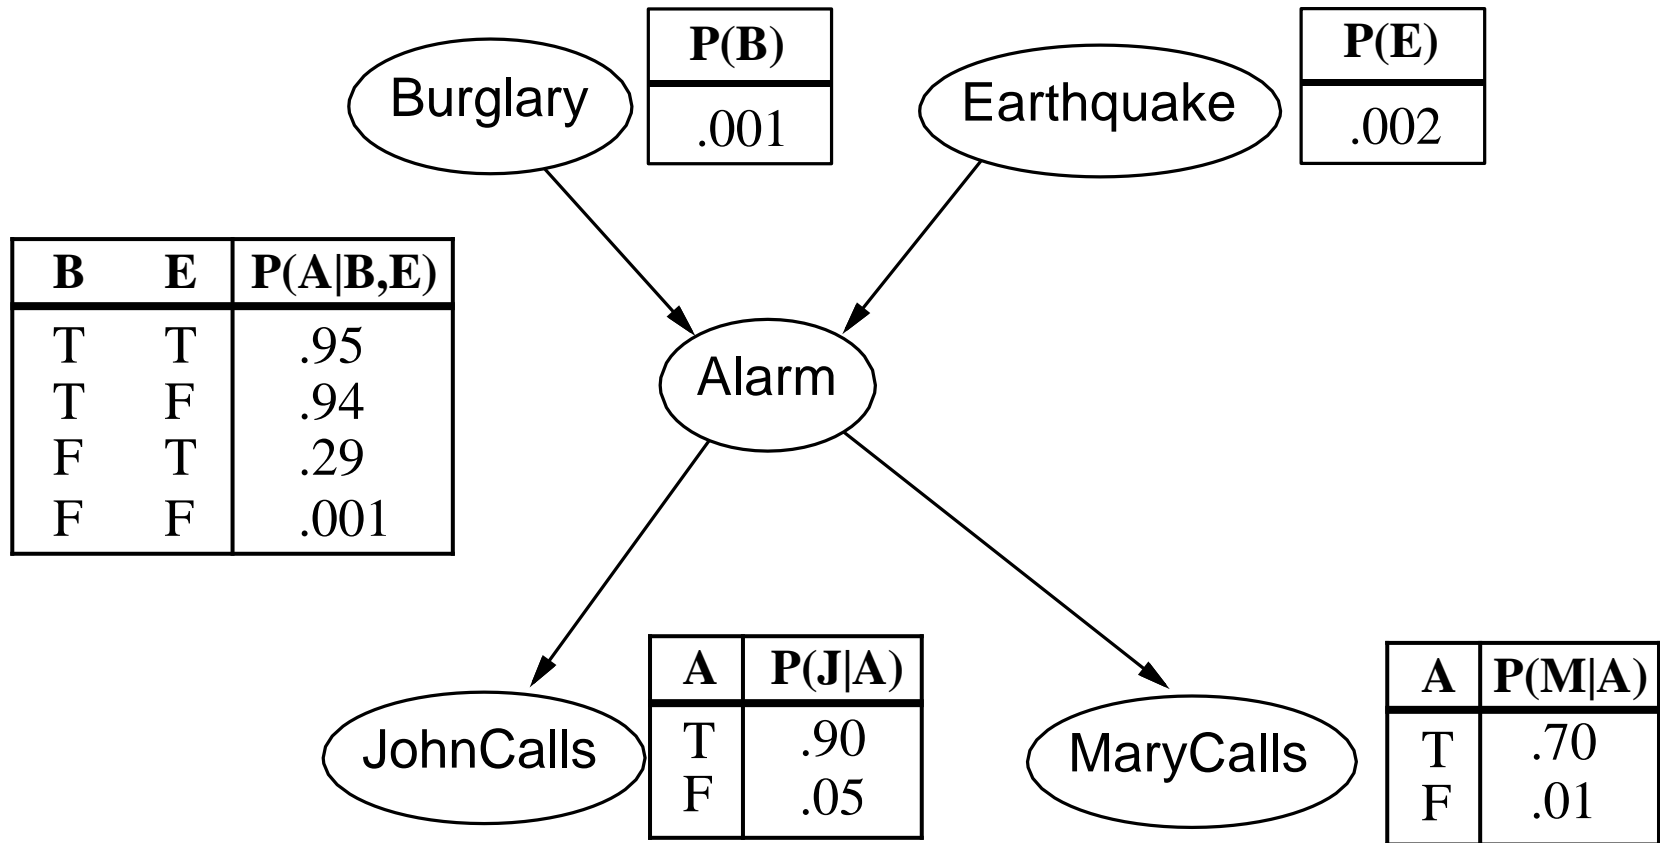
黑小马资讯：快车关键词库来源更新一键优化利润统计上...

9383 阅读

家庭报警器

- 我在上班，邻居约翰打电话来说我的家里的警报响了，但是邻居玛丽没有打电话。有时它是由小地震引起的。有窃贼吗？
- 变量： *Burglar*, *Earthquake*, *Alarm*, *JohnCalls*, *MaryCalls*
- 我们可以用网络拓扑来定义“因果性”的知识：
 - 夜贼能触发报警器
 - 地震可以触发警报
 - 警报会让玛丽打电话
 - 警报会让约翰打电话

家庭报警器



紧凑度


- 对于布尔变量 X_i ，它有 k 个布尔型父代，那么将一共有 2^k 个不同的父代值的组合，称这一指标为紧凑度 (CPT, Compact)
- 每一组父代值组合都有一个概率值 p 来使得 $X_i = true$
- 同样，对于 $X_i = false$ ，父代值的组合概率值是 $1 - p$
- 如果每个变量的父代不超过 k 个
- 那么完整的网络需要个 $O(n \cdot 2^k)$ 概率值
- 也就是说如果网络节点规模按照 n 线性增长，则联合概率的复杂度将按照 $O(2^n)$ 增长
- 对于警报网络，一共有个概率值 $1 + 1 + 4 + 2 + 2 = 10$
 - 作为比较 $2^5 - 1 = 31$

全局语义

- 全局语义将完全联合分布定义为局部条件分布的乘积：

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i \mid \text{parents}(X_i))$$


$$\begin{aligned} &P(j \wedge m \wedge a \wedge \neg b \wedge \neg e) \\ &= P(j|a)P(m|a)P(a|\neg b, \neg e)P(\neg b)P(\neg e) \\ &= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998 \\ &\approx 0.00063 \end{aligned}$$



$$\begin{aligned} &P(j \wedge \neg m \wedge b) = P(j|a)P(m|a)P(a|b) \\ &+ P(j|\neg a)P(m|\neg a)P(\neg a|b)P(b) \end{aligned}$$

局部语义


- 局部语义：每个节点都有条件地独立于给定父节点的非子节点




- 定理：局部语义 \Leftrightarrow 全局语义

马尔科夫毯

- 每个节点都有条件地独立于所有其他节点，给出其**马尔科夫毯**：父节点+子节点+子节点的父节点



马尔科夫毯示例



马尔科夫毯作用

- 在一个随机变量的全集 U 中，目标变量 T 和其非马尔科夫毯变量条件独立
- 这意味着对于 T 而言，所有非马尔科夫毯变量都是冗余的
- 如果要了解目标变量的分布情况，仅需要了解马尔科夫毯的信息即可，不需要对整个数据集进行了解
- 这项特性主要用于在特征空间中选择特征，利用马尔科夫毯可以去除两种类型的特征：不相关特征和冗余特征
- 马尔科夫毯是特征冗余性分析的一种常用工具

构建贝叶斯网络

- 需要一种方法，使一系列条件独立性的本地可测试断言能够保证所需的全局语义

1. 选择变量 X_1, \dots, X_n 的一种排序
2. For $i=1$ to n
3. 将 X_i 加入网络
4. 选择 X_1, \dots, X_{i-1} 的父代节点，使得

$$P(X_i | Parents(X_i)) = P(X_i | X_1, \dots, X_{i-1})$$

- 这种对父代节点的选择方式保证了全局语义：

$$\begin{aligned} P(X_1, \dots, X_n) &= \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1}) && \text{(链式法则)} \\ &= \prod_{i=1}^n P(X_i | Parents(X_i)) && \text{(变换后)} \end{aligned}$$

构建贝叶斯网络示例

- 假设我们选择顺序按照 M , J , A , B , E


MaryCalls

JohnCalls

- $P(J|M) = P(J)$?

构建贝叶斯网络示例


- 假设我们选择顺序按照 M , J , A , B , E



- $P(J|M) = P(J)$? No
- $P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$?

构建贝叶斯网络示例


- 假设我们选择顺序按照 M , J , A , B , E



- $P(J|M) = P(J)$? No
- $P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$? No
- $P(B|A, J, M) = P(B|A)$?
- $P(B|A, J, M) = P(B)$?

构建贝叶斯网络示例


- 假设我们选择顺序按照 M , J , A , B , E



- $P(J|M) = P(J)$? No
- $P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$? No
- $P(B|A, J, M) = P(B|A)$? Yes
- $P(B|A, J, M) = P(B)$? No
- $P(E|B, A, J, M) = P(E|A)$?
- $P(E|B, A, J, M) = P(E|A, B)$?


构建贝叶斯网络示例

- 假设我们选择顺序按照 M , J , A , B , E



- $P(J|M) = P(J)$? No
- $P(A|J, M) = P(A|J)$? $P(A|J, M) = P(A)$? No
- $P(B|A, J, M) = P(B|A)$? Yes
- $P(B|A, J, M) = P(B)$? No
- $P(E|B, A, J, M) = P(E|A)$? No
- $P(E|B, A, J, M) = P(E|A, B)$? Yes

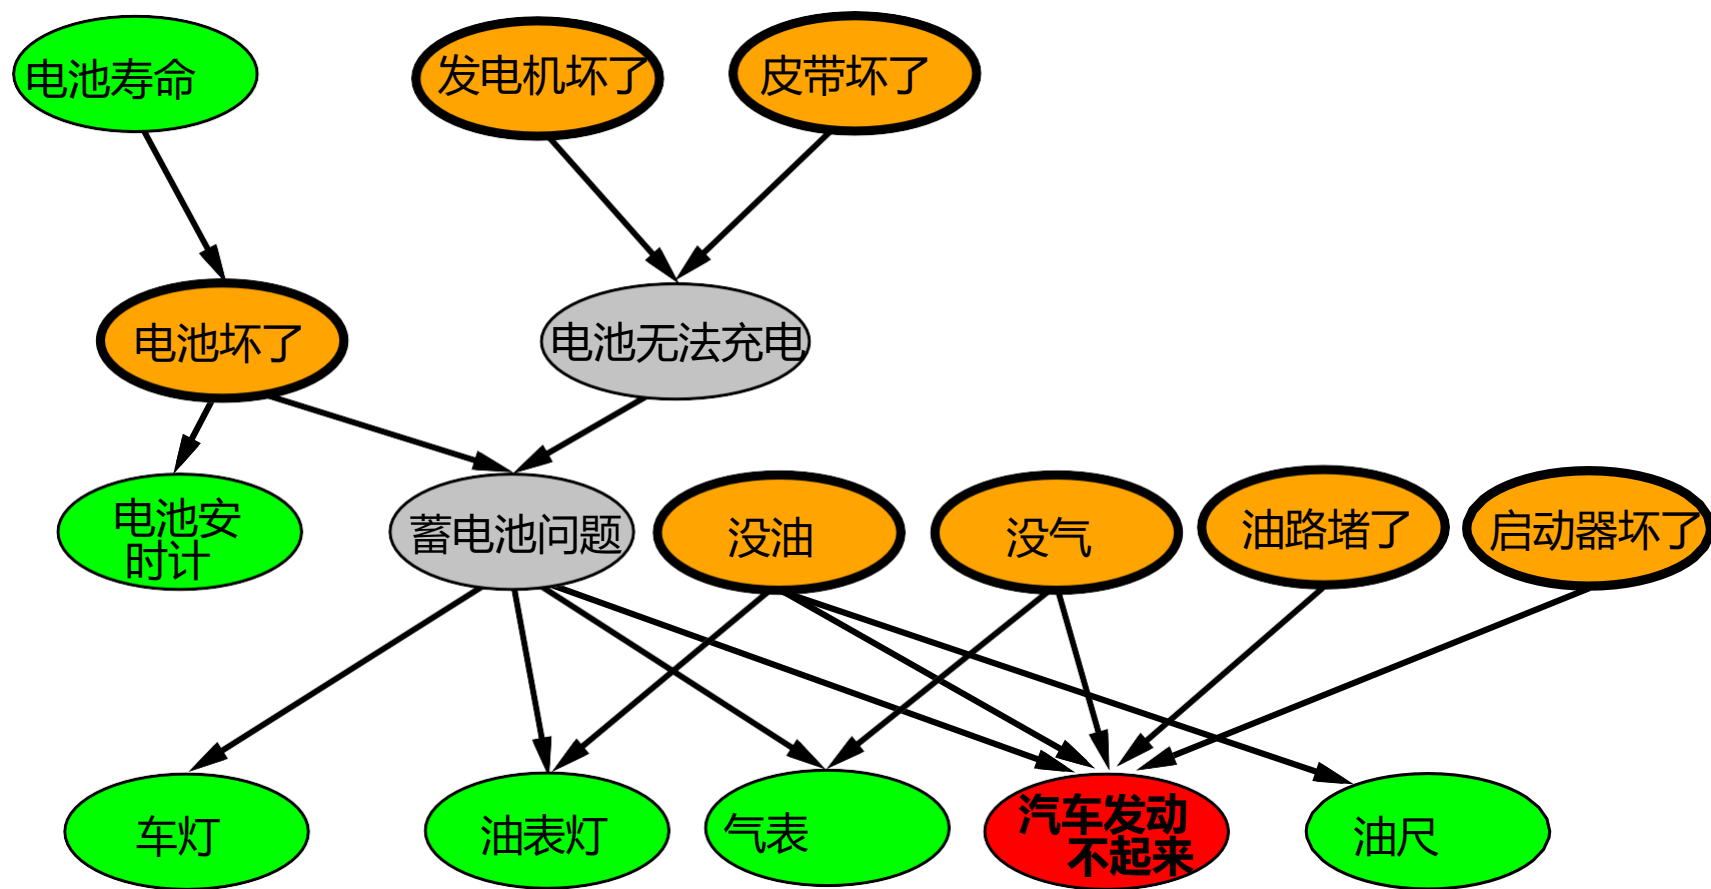
构建贝叶斯网络示例



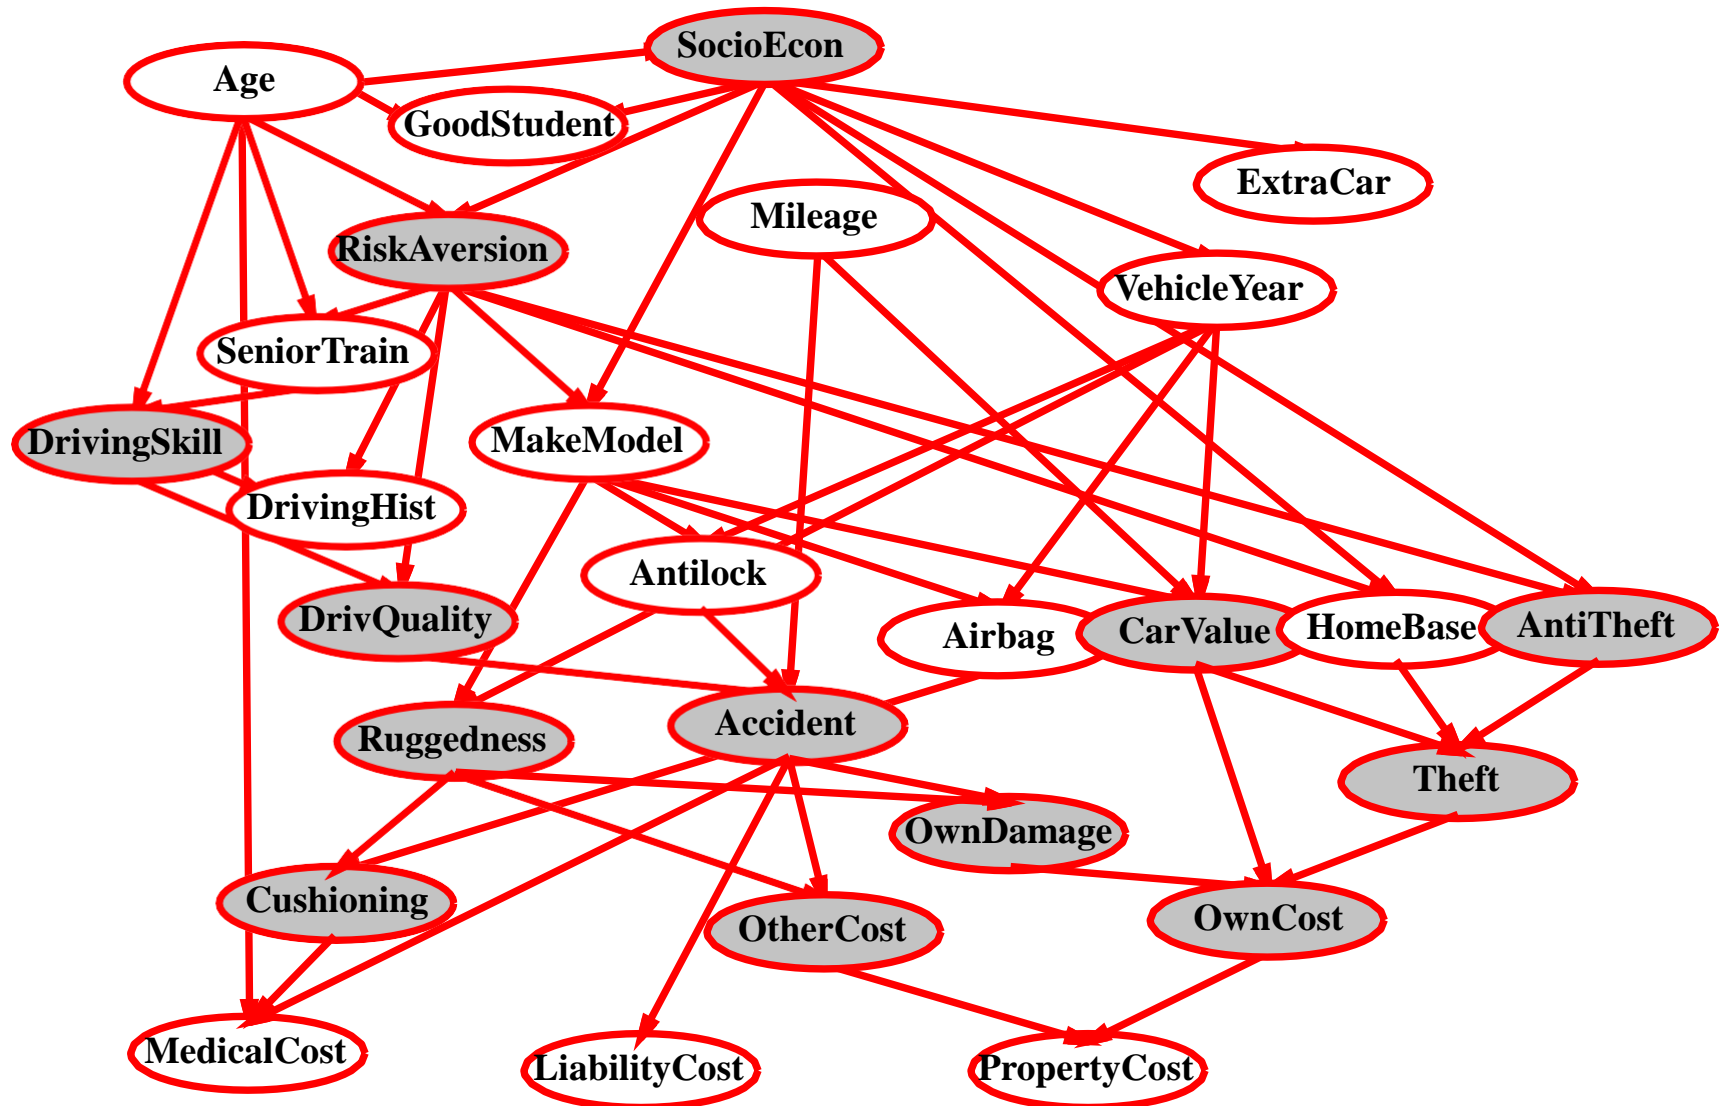
- 在非因果方向上，实现条件独立很困难（人类与生俱来似乎就可以得到因果模型和条件独立性的能力）
- 这也意味着，在非因果方向上评估条件概率是困难的
- 因为网络不那么紧凑，需要 $1+2+4+2+4=13$ 个概率值
 - 作为比较，总共的状态组合是 $2^5-1=31$

实例：汽车诊断

- 汽车发动不起来，如何确定问题
- 可测试的变量、**“坏掉的”** 变量、隐藏变量



实例：汽车保险



紧凑条件分布

- 随着父节点的增加，紧凑度CPT程指数增长
- 如果父节点或子节点是连续值的时候，CPT会变为无限大
- 解决方案：将分布规范定义为已知节点上的最简单的情况

对某一个函数 f 来说 $X = f(Parents(X))$

- 例如：对于布尔函数

华中地区 \Leftrightarrow 湖北省 \vee 湖南省 \vee 我省

- 例如：对于某地水量（连续值）的和时间的数值关系

$$\frac{\partial Level}{\partial t} = \text{流入} + \text{降水} - \text{流出} - \text{蒸发}$$

紧凑条件分布


- 噪声或分布模型有多个非相互作用的原因
 - 父节点 $U_1 \dots U_k$ 包括所有的原因
 - 对于每一个原因，都有概率 q_i 导致独立性失败：
 $\Rightarrow P(X|U_1 \dots U_j, \neg U_{j+1} \dots \neg U_k) = 1 - \prod_{i=1} q_i$

感冒	流感	疟疾	$P(\text{发烧})$	$P(\neg \text{发烧})$
F	F	F	0.0	1.0
F	F	T	0.9	0.1
F	T	F	0.8	0.2
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	0.6
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

- 参数个数与父节点个数成线性关系

混合(离散+连续)网络

- 离散(补贴和购买)、连续的(收获和成本)



- 选择1：离散化——可能有较大的误差，较大的CPT
- 选择2：有限参数化正则族
- 连续变量，离散+连续双亲(例如：成本)
- 离散变量，连续双亲(例如：购买?)

连续子代变量

- 对于给定连续双亲的子变量，需要一个条件密度函数，对于每个可能的离散双亲赋值


- 最常见的是线性高斯模型 (LG) ， 例如：

$$\begin{aligned} &P(\text{Cost} = c | \text{Harvest} = h, \text{Subsidy?} = \text{true}) \\ &= N(a_t h + b_t, \sigma_t)(c) = \frac{1}{\sigma_t \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{c - (a_t h + b_t)}{\sigma_t} \right)^2} \end{aligned}$$

- 平均 Cost 随 Harvest 线性变化，方差是固定的
- 线性变化在整个定义域范围内是不合理的，但如果可能的自变量范围很窄也可以（为什么？）


连续子代变量

- 具有线性高斯分布 (LG) 的全连续网络
- \Rightarrow 完全联合分布是一个多元高斯分布
- 离散+连续的LG网络是一个条件高斯网络。对于每个离散变量值的组合的所有连续变量满足多元高斯分布 (multivariate Gaussian)



P(离散变量w | 连续双亲)

- 给定成本曲线，如果要计算购买的可能性，那么成本的阈值将是一个“软性”的阈值




- probit分布采用高斯积分：

$$\Phi(x) = \int_{-\infty}^x N(0,1)(x) dx$$

$$P(\text{Buys?} = \text{true} | \text{Cost} = c) = \Phi((-c + \mu)/\sigma)$$

为什么使用probit?

- 1、概率有正确的形状
- 2、概率可以当做“硬” 阈值，其位置受噪音的影响




离散变量

- Sigmoid(或logit)分布也用于神经网络:

$$P(\text{Buys?} = \text{true} | \text{Cost} = c) = \frac{1}{1 + \exp(-2 \frac{-c + \mu}{\sigma})}$$

- Sigmoid的形状与probit相似，但尾巴要长得多:



总结

- 贝叶斯网络为（因果性）条件独立提供了一种自然表示
- 拓扑+ CPTs = 联合分布的紧凑表示
- 通常易于（非）专家构造概率分布使用
- 正则分布（例如噪声）=CPT的紧凑分布
- 连续变量 \Rightarrow 参数化分布（如线性高斯模型LG）

