

Artificial Intelligence

8. 不确定知识与推理c

对应课本13-15章

贝叶斯网络推理

- 使用枚举进行精准推理
- 通过消除变量进行精准推理
- 随机模拟的逼近推理
- 马尔科夫链蒙特卡罗逼近推理

推理任务

- 简单查询：计算后验边缘概率 $P(X_i|E = e)$
 - 例如 $P(\text{NoGas}|\text{Gauge} = \text{empty}, \text{Lights} = \text{on}, \text{Starts} = \text{false})$
- 连接查询： $P(X_i, X_j|E = e) = P(X_i|E = e)P(X_j|X_i, E = e)$
- 最优决策：决策网络包括效用信息
 - 概率推理需要 $P(\text{outcome}|\text{action}, \text{evidence})$
- 信息价值：下一步找什么证据？
- 敏感性分析：哪些概率值是最关键的？
- 对答案的解释：为什么我需要一个新的启动器？

通过枚举的推理

- 这种方法，可以从节点的交叉中计算出变量，而不需要构造交叉状态的显式表示

- 简单查询入室行窃网络：

$$P(B|j, m)$$

$$= P(B, j, m)/P(j, m)$$

$$= \alpha P(B, j, m)$$

$$= \alpha \sum_e \sum_a P(B, e, a, j, m)$$

- 使用条件概率表(CPT)的乘积重写完整的联合项：

$$P(B|j, m)$$


$$= \alpha \sum_e \sum_a P(B)P(e)P(a|B, e)P(j|a)P(m|a)$$

$$= \alpha P(B) \sum_e P(e) \sum_a P(a|B, e)P(j|a)P(m|a)$$

- 递归深度优先枚举

- 时间复杂度： $O(n)$

- 空间复杂度： $O(d^n)$



枚举算法

function **Enumeration-Ask**(X , e , bn) returns a distribution over X

inputs: X , the query variable

e , observed values for variables E

bn , a Bayesian network with variables $\{X\} \cup E \cup Y$

$Q(X) \leftarrow$ a distribution over X , initially empty

for each value x_i of X do

 extend e with value x_i for X

$Q(x_i) \leftarrow \text{Enumerate-All}(\text{Vars}[bn], e)$ return

$\text{Normalize}(Q(X))$

function **Enumerate-All**($vars$, e) returns a real number

if Empty?($vars$) then return 1.0

$Y \leftarrow \text{First}(vars)$


if Y has value y in e

 then return $P(y|Pa(Y)) \times \text{Enumerate-All}(\text{Rest}(vars), e)$

 else return $\sum_y P(y|Pa(Y)) \times \text{Enumerate-All}(\text{Rest}(vars), e_y)$

 where e_y is e extended with $Y = y$

评价树



- 枚举效率低：需要重复计算每个值
 - 比如对于 e 的每个取值需要计算 $P(j|a)P(m|a)$

变量消除推理

- 变量消除：从右到左进行求和，存储中间结果(因子)，避免重新计算

$$\begin{aligned} & \mathbf{P}(B|j, m) \\ &= \alpha \underbrace{\mathbf{P}(B)}_B \underbrace{\sum_e P(e)}_E \underbrace{\sum_a \mathbf{P}(a|B, e)}_A \underbrace{P(j|a)}_J \underbrace{P(m|a)}_M \\ &= \alpha \mathbf{P}(B) \sum_e P(e) \sum_a \mathbf{P}(a|B, e) P(j|a) f_M(a) \\ &= \alpha \mathbf{P}(B) \sum_e P(e) \sum_a \mathbf{P}(a|B, e) f_J(a) f_M(a) \\ &= \alpha \mathbf{P}(B) \sum_e P(e) \sum_a f_A(a, b, e) f_J(a) f_M(a) \\ &= \alpha \mathbf{P}(B) \sum_e P(e) f_{\bar{A}JM}(b, e) \text{ (sum out } A) \\ &= \alpha \mathbf{P}(B) f_{\bar{E}\bar{A}JM}(b) \text{ (sum out } E) \\ &= \alpha f_B(b) \times f_{\bar{E}\bar{A}JM}(b) \end{aligned}$$

变量消除：基本操作

- 从因子乘积中得出一个变量：
- 把常数移到求和之外
- 将剩余因子的点积中的子矩阵相加

$$\sum_x f_1 \times \cdots \times f_k = f_1 \times \cdots \times f_i \sum_x f_{i+1} \times \cdots \times f_k = f_1 \times \cdots \times f_i \times f_x$$

- 假设 f_1, \dots, f_i 并不依赖于 X
- 因此可以计算 f_1 的 f_2 的点积

$$\begin{aligned} f_1(x_1, \dots, x_j, y_1, \dots, y_k) \times f_2(y_1, \dots, y_k, z_1, \dots, z_l) \\ = f(x_1, \dots, x_j, y_1, \dots, y_k, z_1, \dots, z_l) \end{aligned}$$

- 如 $f_1(a, b) \times f_2(b, c) = f(a, b, c)$


变量消除算法

```
function Elimination-Ask( $X$ ,  $e$ ,  $bn$ ) returns a distribution over  $X$ 
  inputs:  $X$ , the query variable
            $e$ , evidence specified as an event
            $bn$ , a belief network specifying joint distribution  $P(X_1, \dots, X_n)$ 

   $factors \leftarrow []$ ;  $vars \leftarrow \text{Reverse}(\text{Vars}[bn])$ 
  for each  $var$  in  $vars$  do
     $factors \leftarrow [\text{Make-Factor}(var, e) | factors]$ 
    if  $var$  is a hidden variable then  $factors \leftarrow \text{Sum-Out}(var, factors)$ 
  return Normalize(Pointwise-Product( $factors$ ))
```


不相关的变量

- 考虑查询语句 $P(\text{JohnCalls} | \text{Burglary} = \text{true})$
$$P(J|b) = \alpha P(b) \Sigma_e P(e) \Sigma_a P(a|b, e) P(J|a) \Sigma_m P(m|a)$$
- 其中, m 的和为1, 而 M 的取值和查询语句无关
- Y 是无关的, 除非 $Y \in \text{Ancestors}(\{X\} \cup E)$
 - 这里 $X = \text{JohnCalls}$, $E = \{\text{Burglary}\}$
 - 并且 $\text{Ancestors}(\{X\} \cup E) = \{\text{Alarm}, \text{Earthquake}\}$
 - 所以 MaryCalls 是无关的
 - (将其与来自Horn子句KBs中的查询的反向链接进行比较)




不相关的变量

- 假设我们将A的父代连在一起，且取消所有的箭头
- 那么我们说A对于B被C隔开，当且仅当A也被C所隔开
- 例如对 $P(\text{JohnCalls} | \text{Alarm} = \text{true})$ 来说，*Burglary* 和 *Earthquake* 都是不相关的



精确推理的复杂性

- 单连通网络(或多树):
 - 任意两个节点最多通过一条(无向)路径连接
 - 变量消去的时间和空间代价为 $O(d^k n)$
- 多连通网络:
 - 能不能把3SAT降低到np-hard精确推理
 - 相当于把3SAT模型算上#P-complete



- 1. $A \vee B \vee C$
- 2. $C \vee D \vee A$
- 3. $B \vee C \vee D$

随机模拟推理

- 基本思想：
 - 从一个抽样分布 S 中抽取 N 个样本
 - 计算一个近似后验概率 \hat{P}
 - 证明这个收敛于真实概率 P
- 要点：
 - 从空网络中抽样
 - 拒绝式抽样：拒绝与证据不符的样品
 - 可能性加权：使用证据对样本进行加权
 - 马尔科夫链蒙特卡洛方法Markov chain Monte Carlo (MCMC)：随机过程的样本，其平稳分布是真实的后验

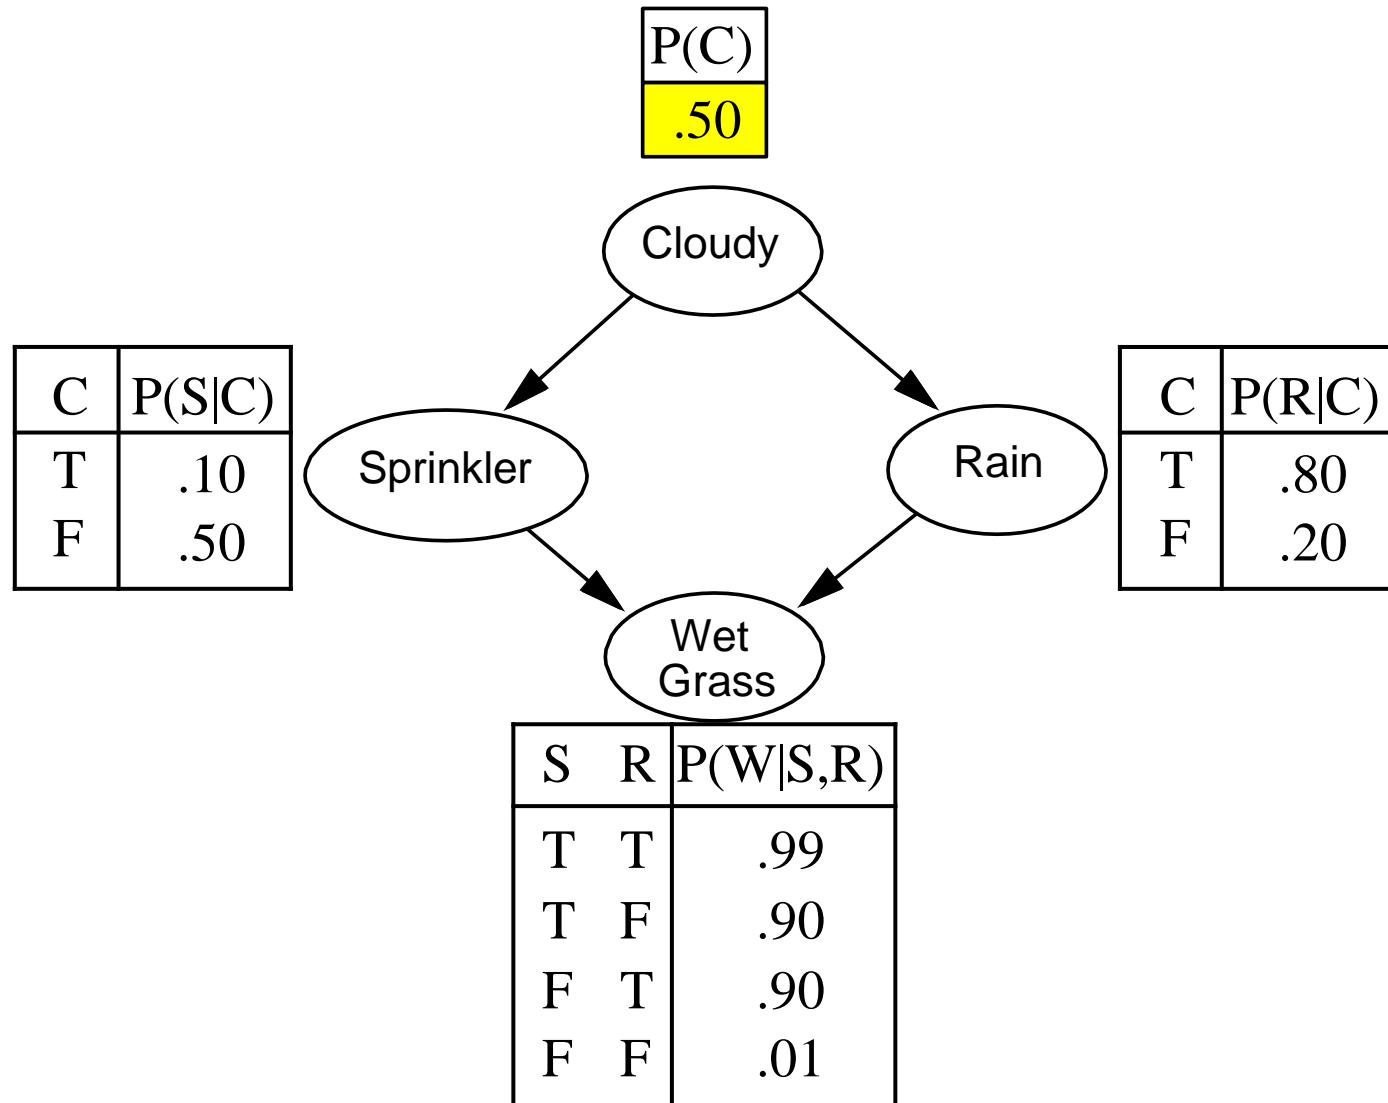
0.5

Coin

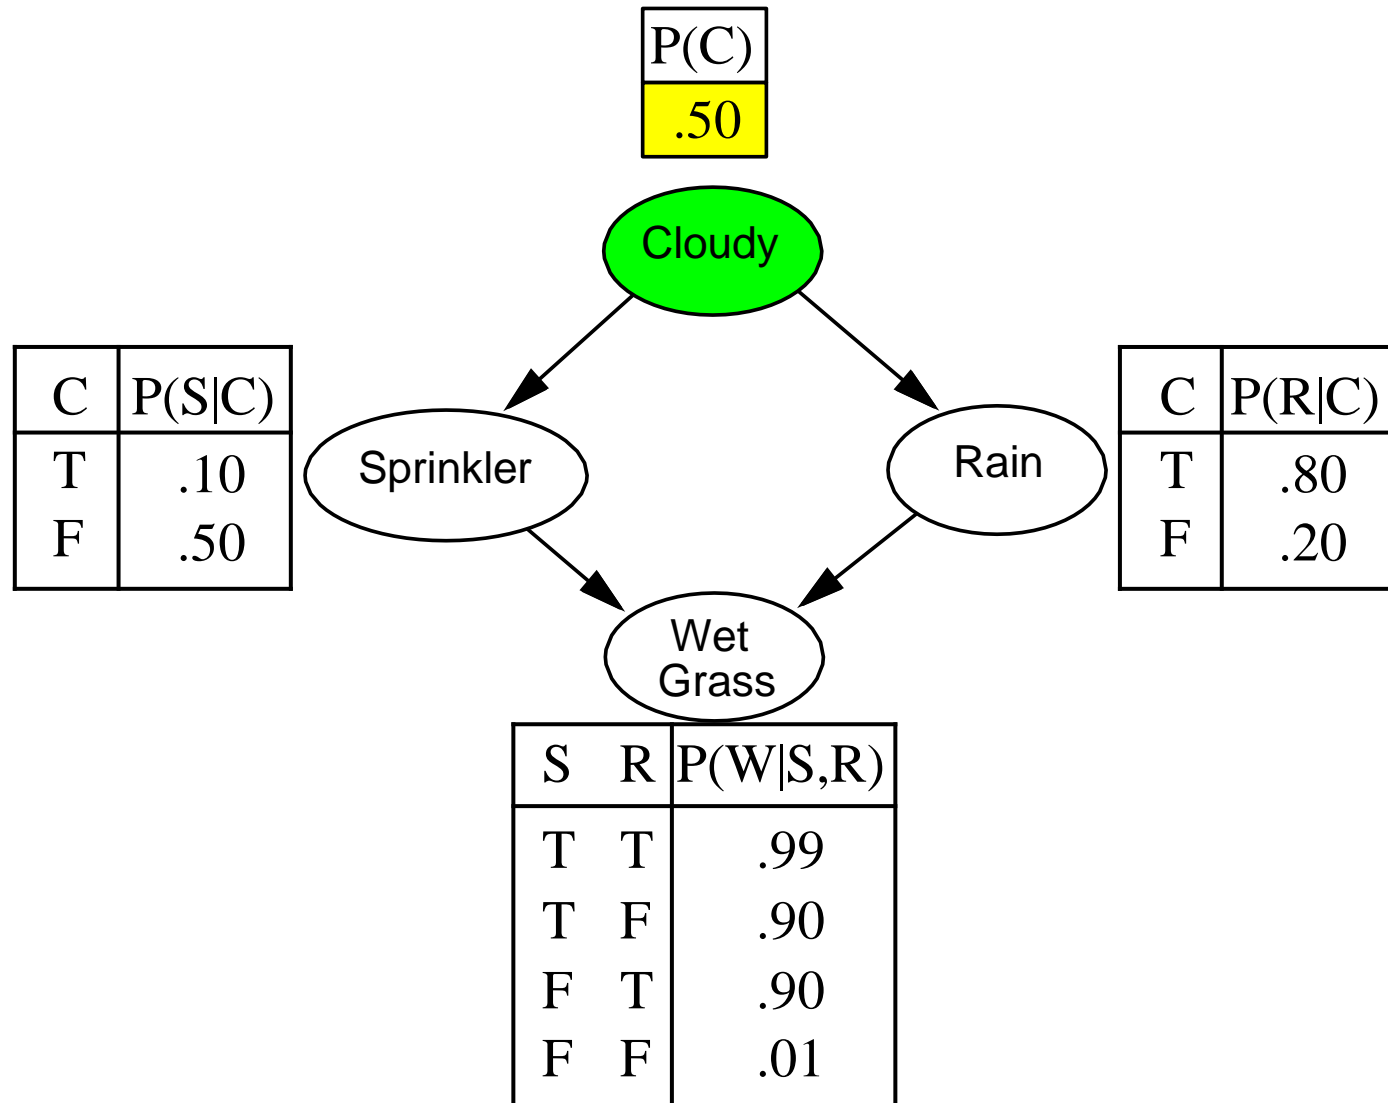
从空网络中采样

```
function Prior-Sample(bn) returns an event sampled from bn  
  inputs: bn, a belief network specifying joint distribution  $P(X_1, \dots, X_n)$   
   $\mathbf{x} \leftarrow$  an event with  $n$  elements  
  for  $i = 1$  to  $n$  do  
     $x_i \leftarrow$  a random sample from  $P(X_i \mid \text{parents}(X_i))$   
    given the values of  $\text{Parents}(X_i)$  in  $\mathbf{x}$   
  return  $\mathbf{x}$ 
```

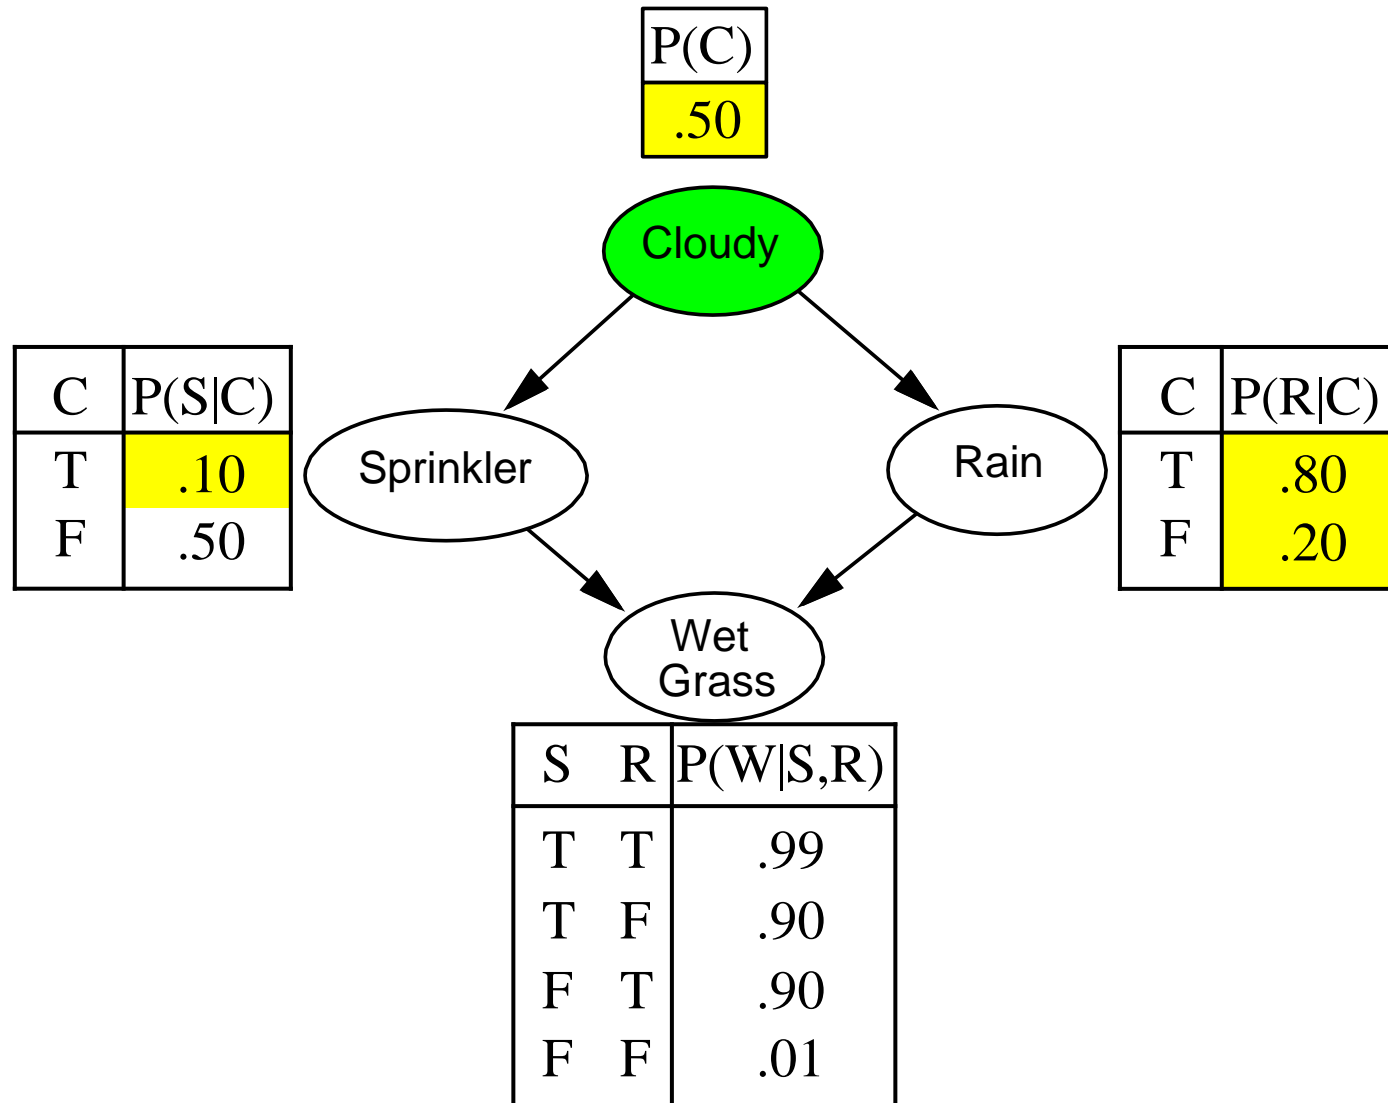
从空网络中采样实例



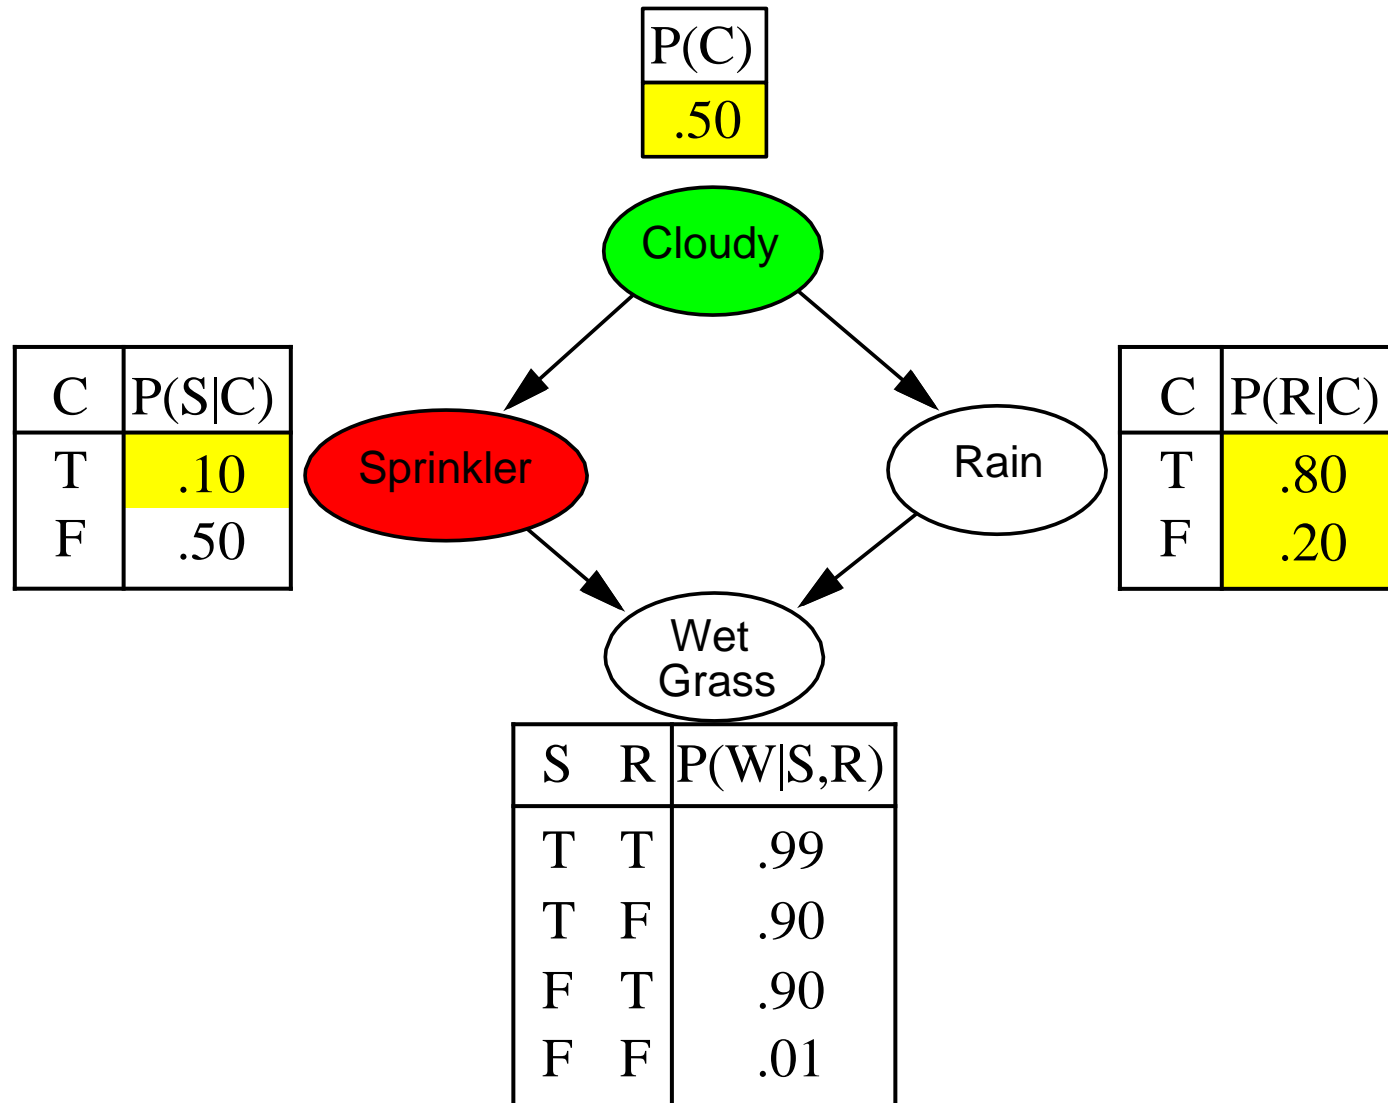
从空网络中采样实例



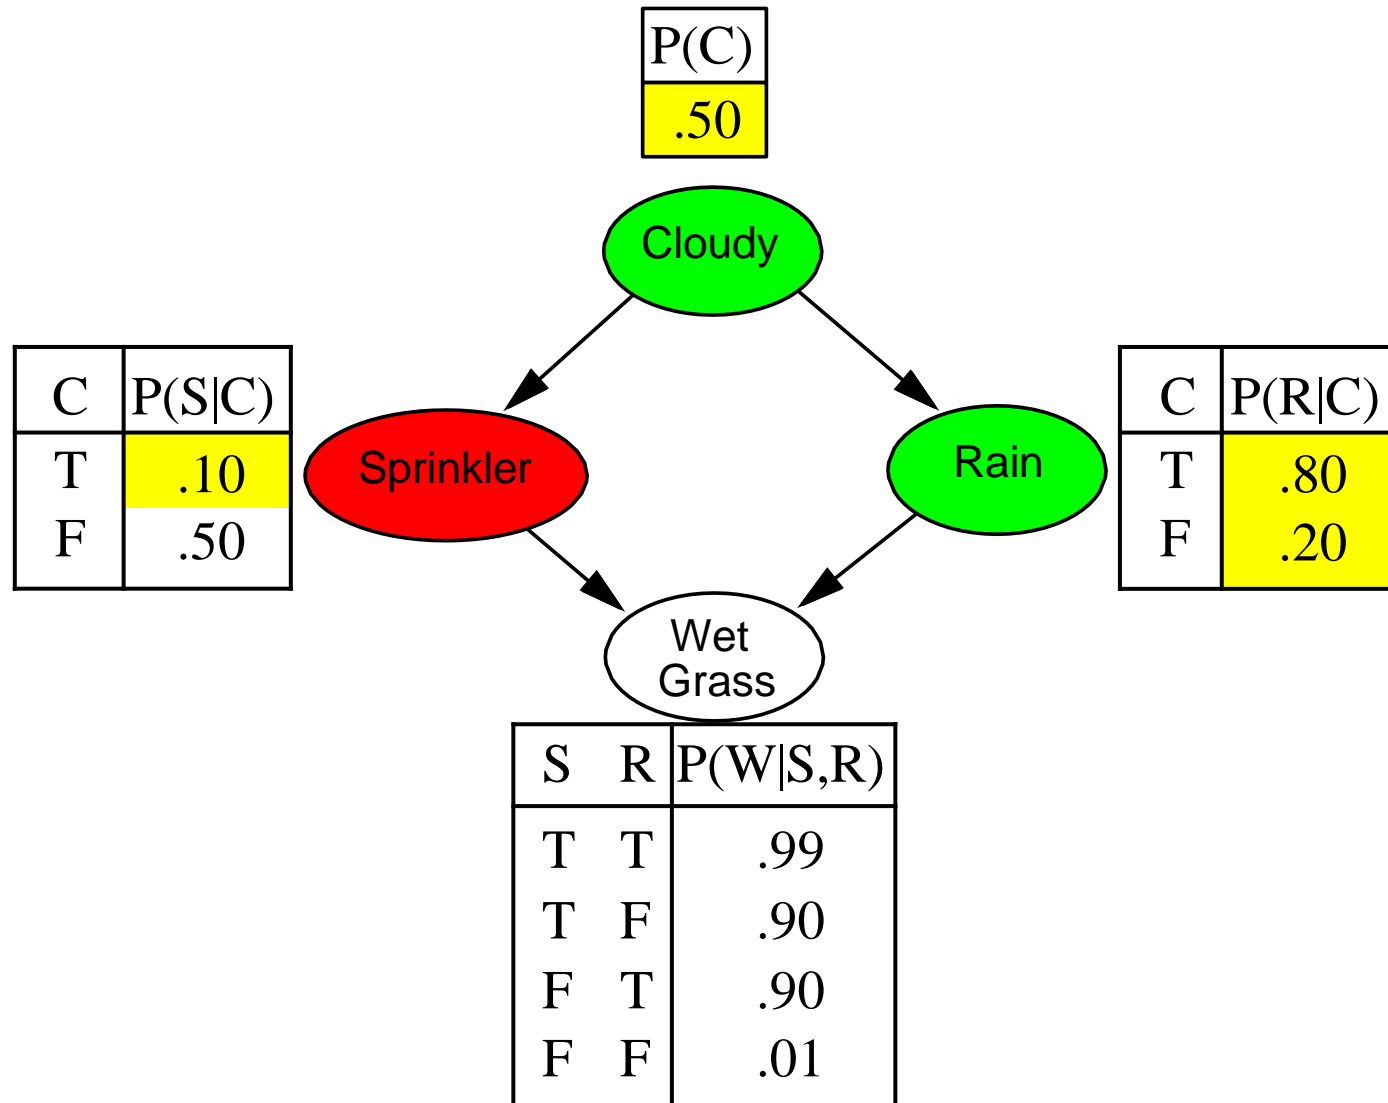
从空网络中采样实例



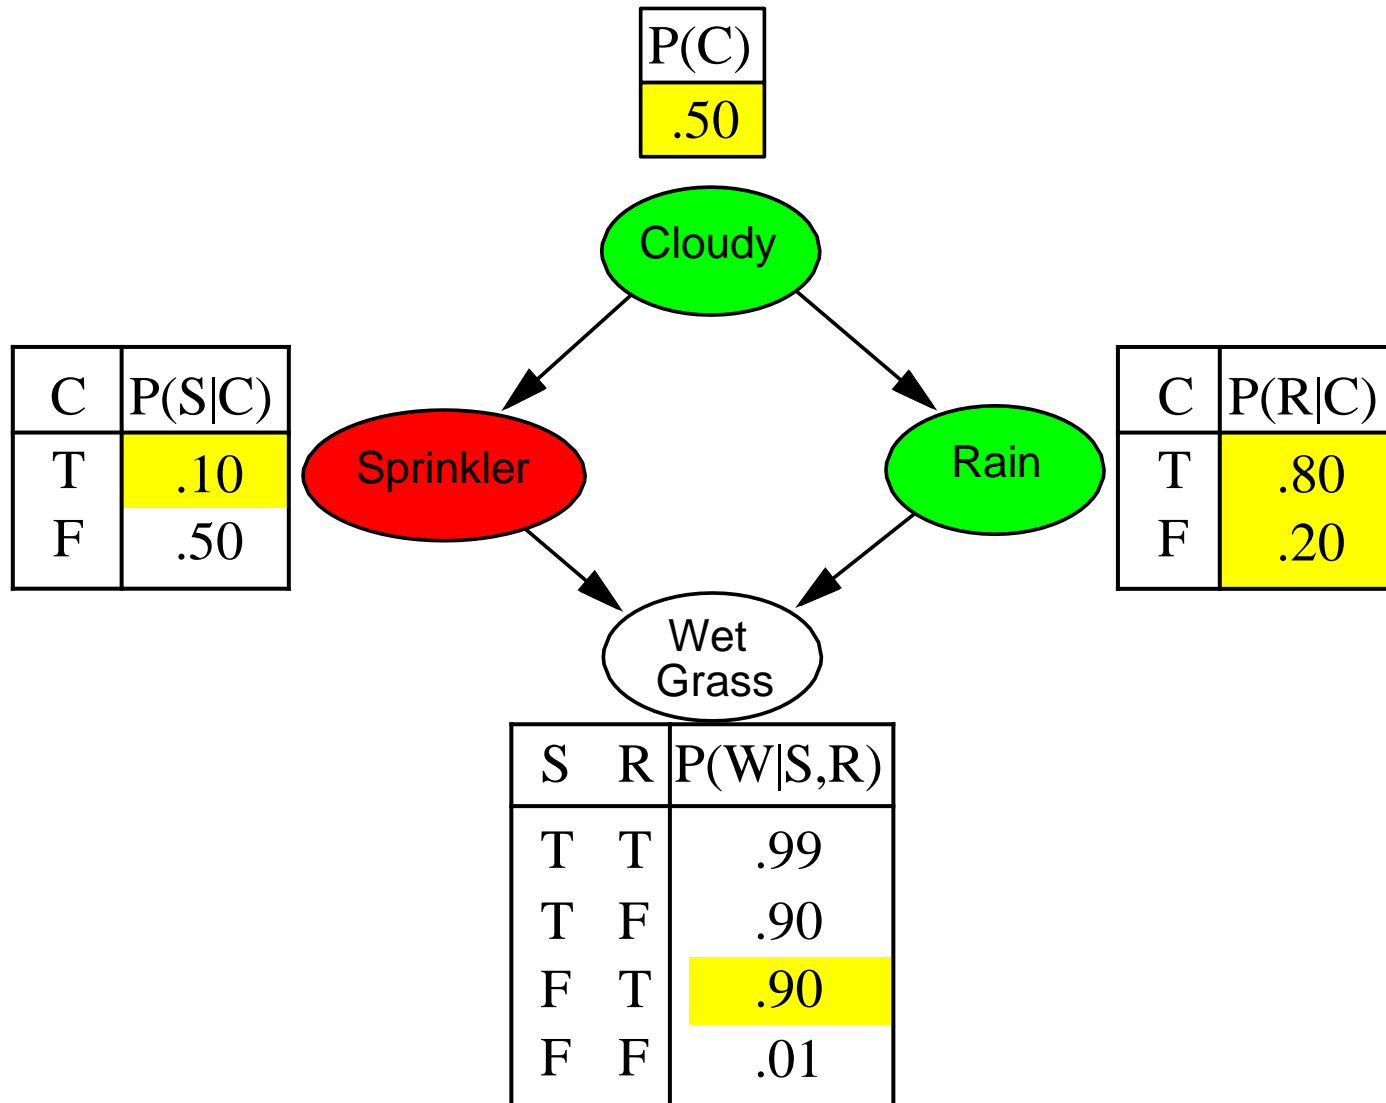
从空网络中采样实例



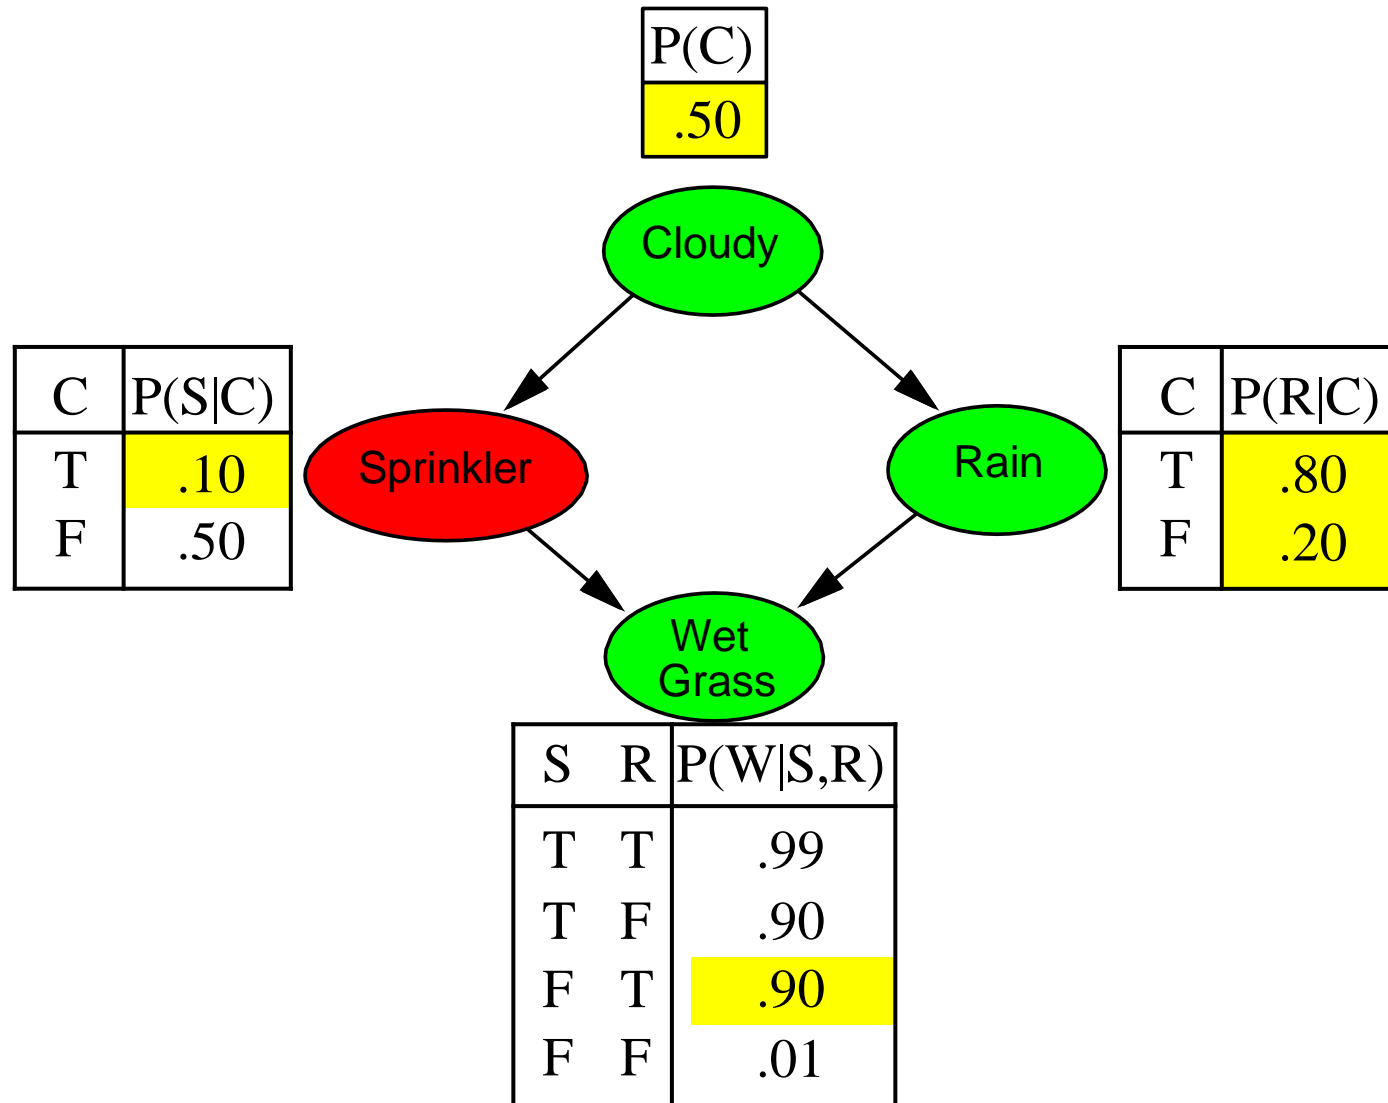
从空网络中采样实例



从空网络中采样实例



从空网络中采样实例



从空网络中采样

- 先验样本产生特定事件的概率

$$S_{ps}(x_1 \dots x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i)) = P(x_1 \dots x_n)$$

- 即真实的先验概率
- 如 $S_{PS}(t, f, t, t) = 0.5 \times 0.9 \times 0.8 \times 0.9 = 0.324 = P(t, f, t, t)$
- 令 $N_{PS}(x_1 \dots x_n)$ 作为采样所生成的事件 x_1, \dots, x_n
- 于是我们有

$$\begin{aligned} \lim_{n \rightarrow \infty} \hat{P}(x_1, \dots, x_n) &= \lim_{N \rightarrow \infty} N_{PS}(x_1, \dots, x_n) / N \\ &= S_{PS}(x_1, \dots, x_n) \\ &= P(x_1 \dots x_n) \end{aligned}$$

- 也就是说，通过先验样本的估计值和真实值是一致的

$$\hat{P}(x_1, \dots, x_n) \approx P(x_1, \dots, x_n)$$

拒绝采样

- $\hat{P}(X|e)$ 可以由样本估算, 符合 e 即可

```
function Rejection-Sampling( $X, e, bn, N$ ) returns an estimate of  $P(X|e)$ 
  local variables:  $N$ , a vector of counts over  $X$ , initially zero
  for  $j = 1$  to  $N$  do
     $x \leftarrow \text{Prior-Sample}(bn)$ 
    if  $x$  is consistent with  $e$  then
       $N[x] \leftarrow N[x] + 1$  where  $x$  is the value of  $X$  in  $x$ 
  return Normalize( $N[X]$ )
```

- 如 $P(\text{Rain} | \text{Sprinkler} = \text{true})$ 使用了100个采样

- 其中27个采样有 $\text{Sprinkler} = \text{true}$

- 其中8个 $\text{Rain} = \text{true}$, 19个 $\text{Rain} = \text{false}$

$$\hat{P}(\text{Rain} | \text{Sprinkler} = \text{true}) = \text{Normalize}((8, 19)) = (0.296, 0.704)$$

- 类似于一个基本的真实世界的经验估计程序

拒绝抽样分析

$$\hat{P}(X|e) = \alpha N_{ps}(X, e)$$

$$= N_{PS}(X, e) / N_{PS}(e)$$

$$\approx P(X, e) / P(e)$$

$$= P(X|e)$$

函数定义

通过 $N_{PS}(e)$ 实现归一化

先验采样的属性

条件概率的定义

- 因此，排斥抽样返回一致的后验估计
- 问题：如果 $P(e)$ 很小，就会非常昂贵
- $P(e)$ 随着证据变量的数量呈指数下降

可能性的权重

- 思路：固定证据变量，只采样非证据变量，并加权每个样本的可能性，使它符合证据

function **Likelihood-Weighting**(X, e, bn, N) returns an estimate of $P(X|e)$

local variables: W , a vector of weighted counts over X , initially zero

for $j = 1$ to N do

$x, w \leftarrow \text{Weighted-Sample}(bn)$

$W[x] \leftarrow W[x] + w$ where x is the value of X in x

return $\text{Normalize}(W[X])$

function **Weighted-Sample**(bn, e) returns an event and a weight

$x \leftarrow$ an event with n elements; $w \leftarrow 1$

for $i = 1$ to n do

 if X_i has a value x_i in e

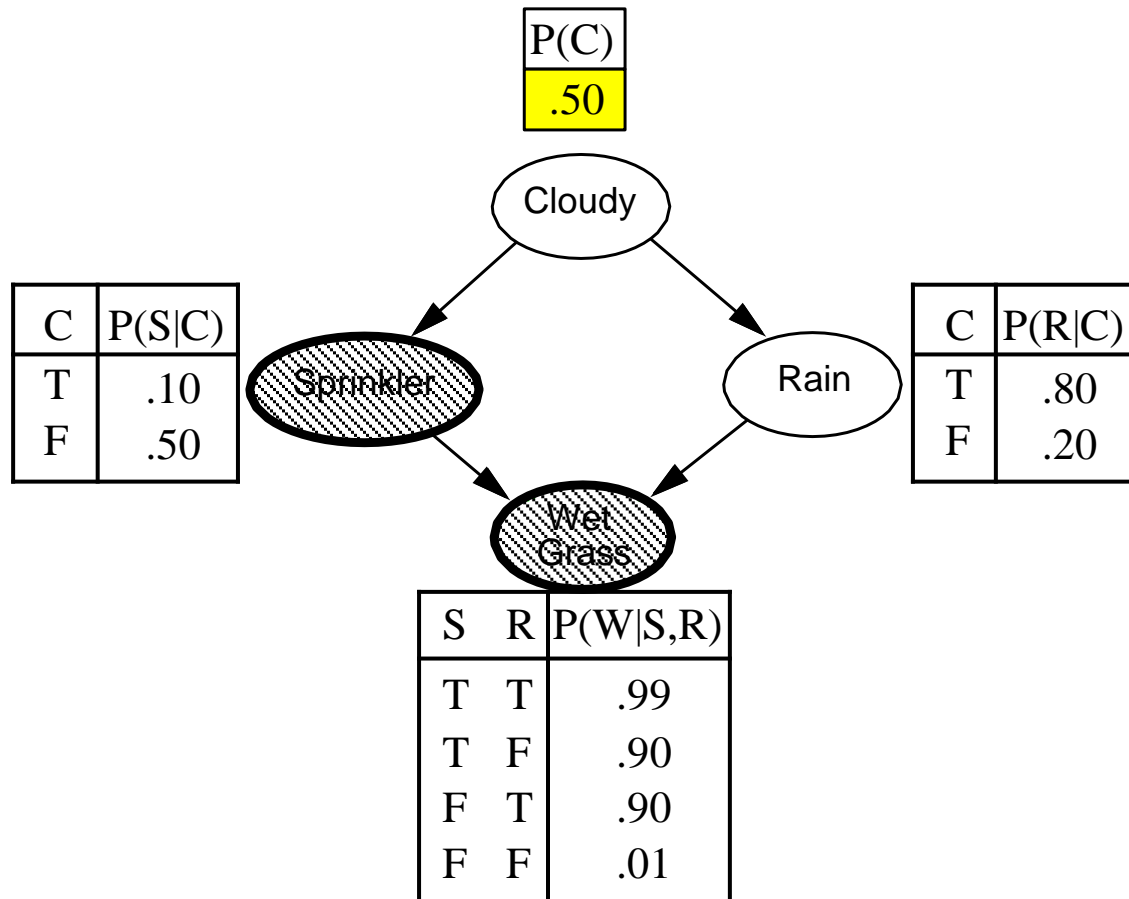
 then $w \leftarrow w \times P(X_i = x_i | \text{parents}(X_i))$

 else $x_i \leftarrow$ a random sample from $P(X_i | \text{parents}(X_i))$

return x, w

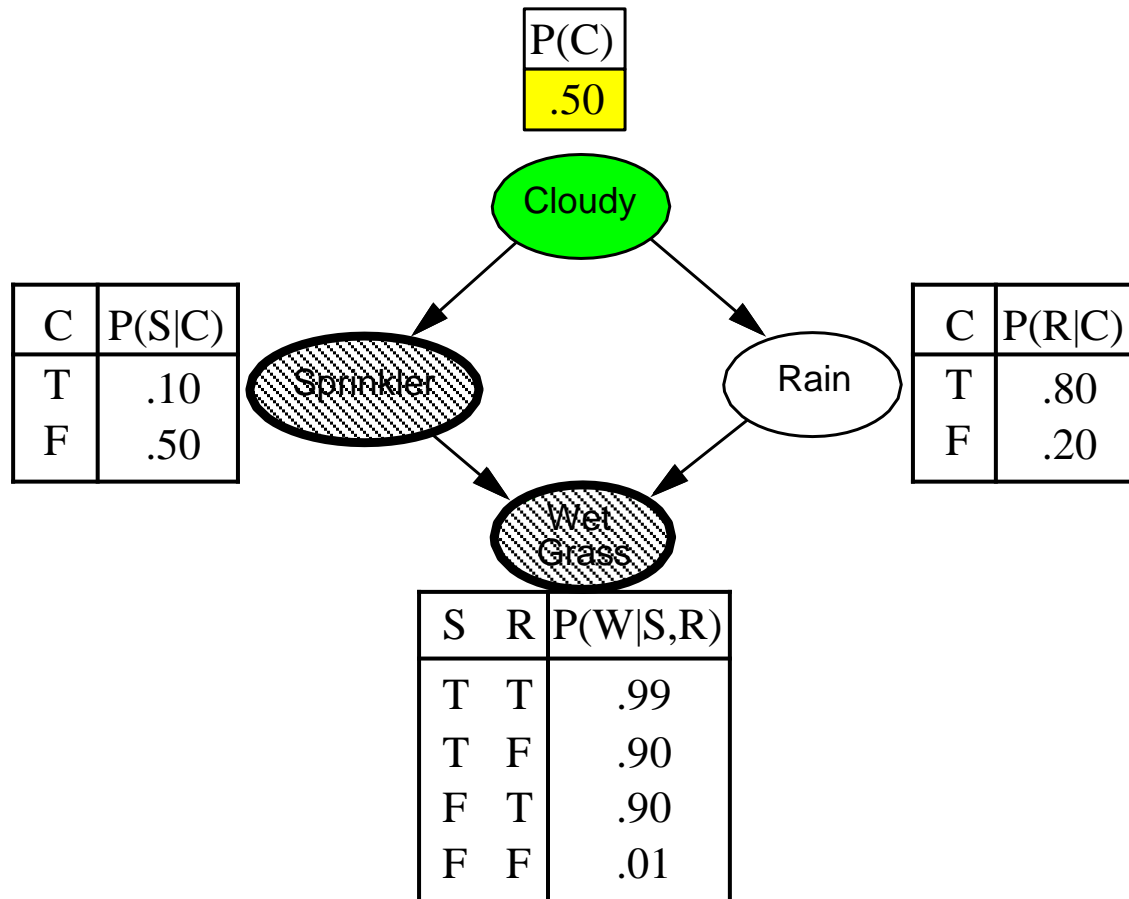
可能性权重的例子

- $w = 1.0$



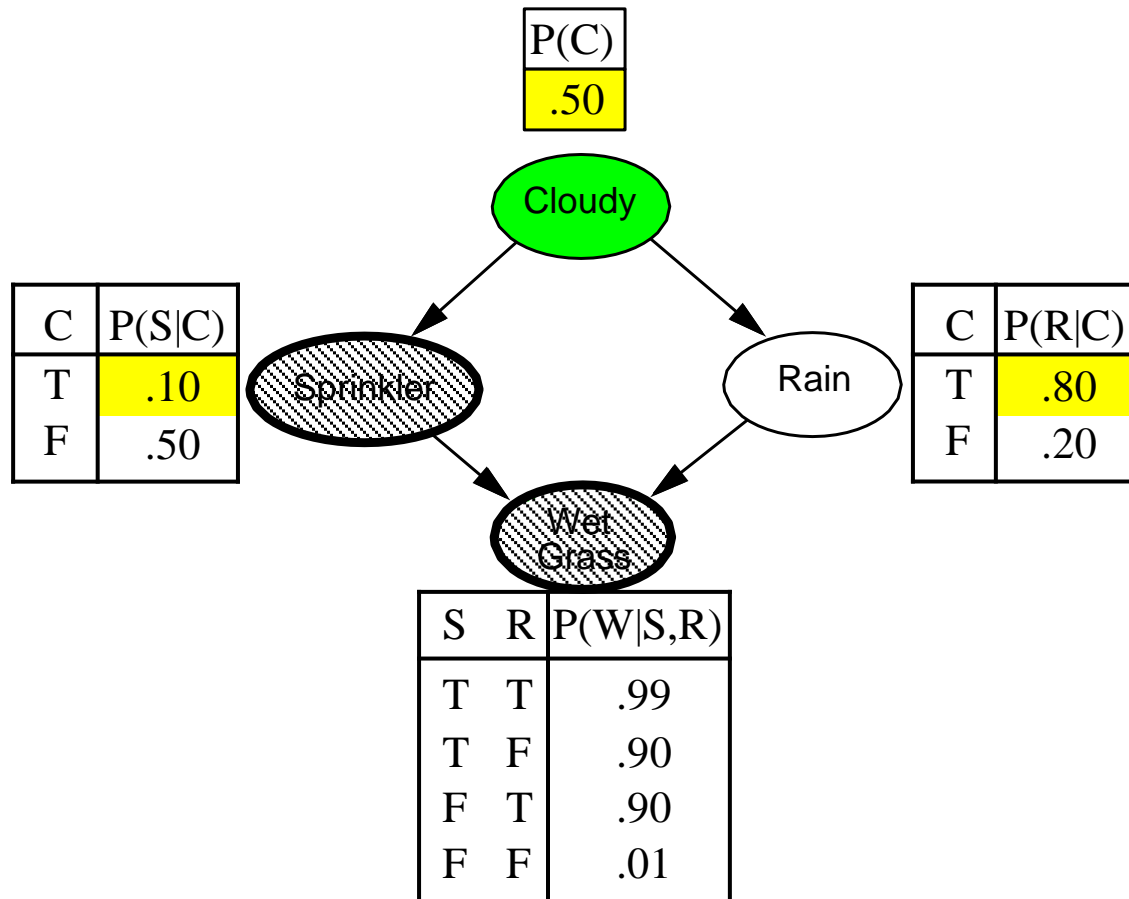
可能性权重的例子

- $w = 1.0$



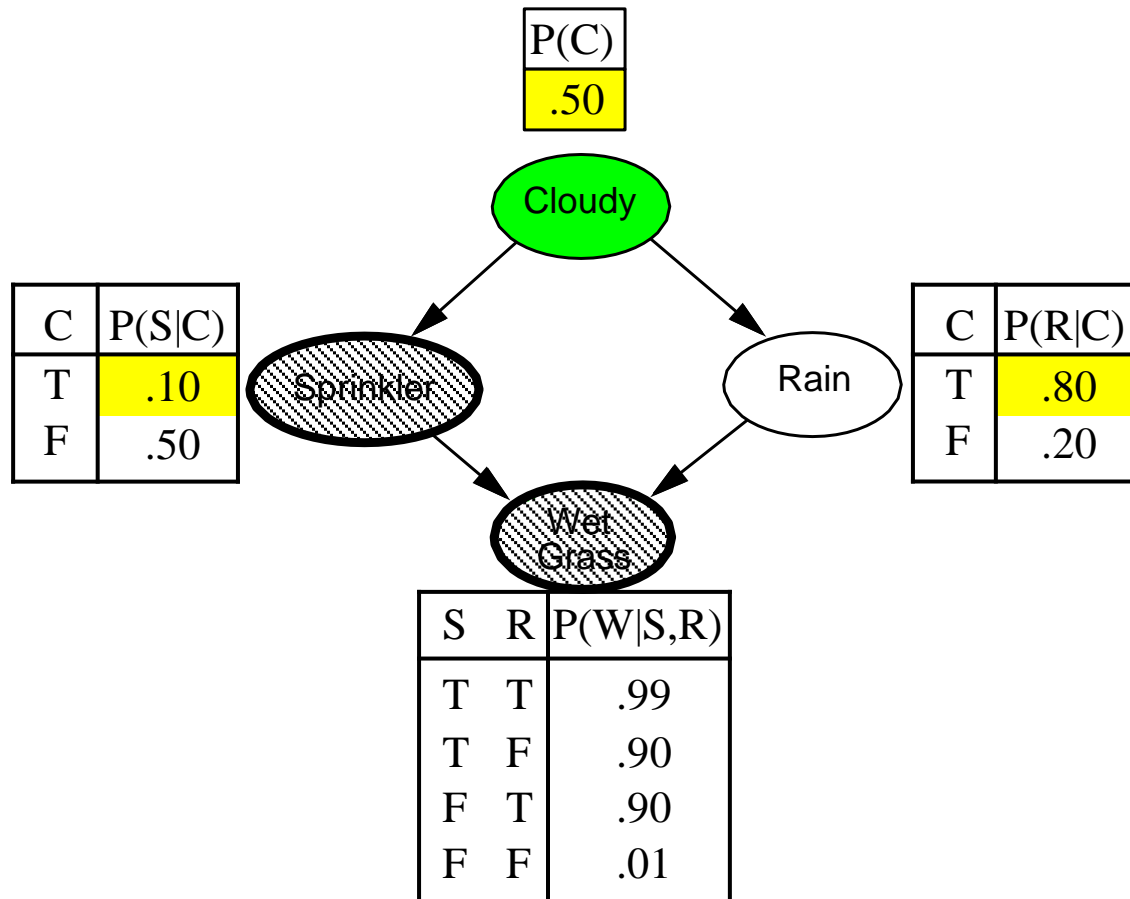
可能性权重的例子

- $w = 1.0$



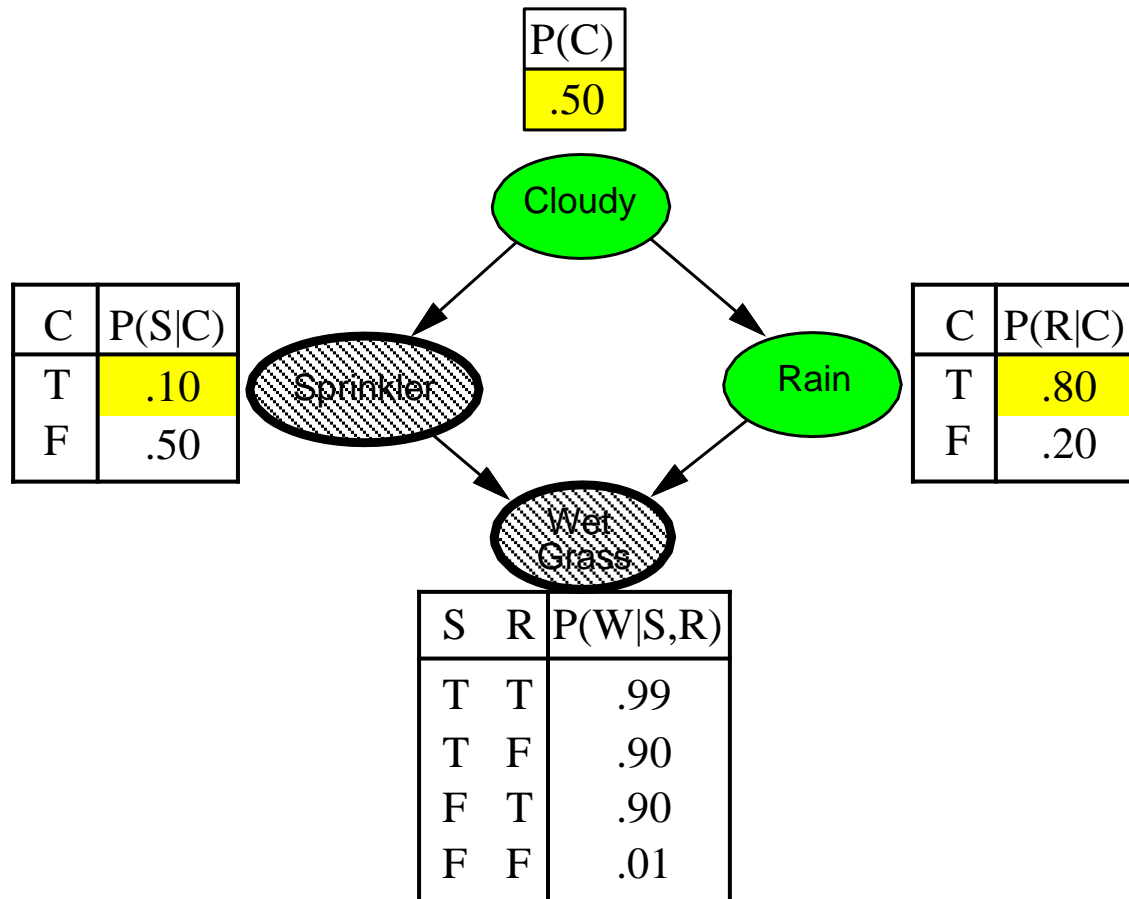
可能性权重的例子

- $w = 1.0 \times 0.1$



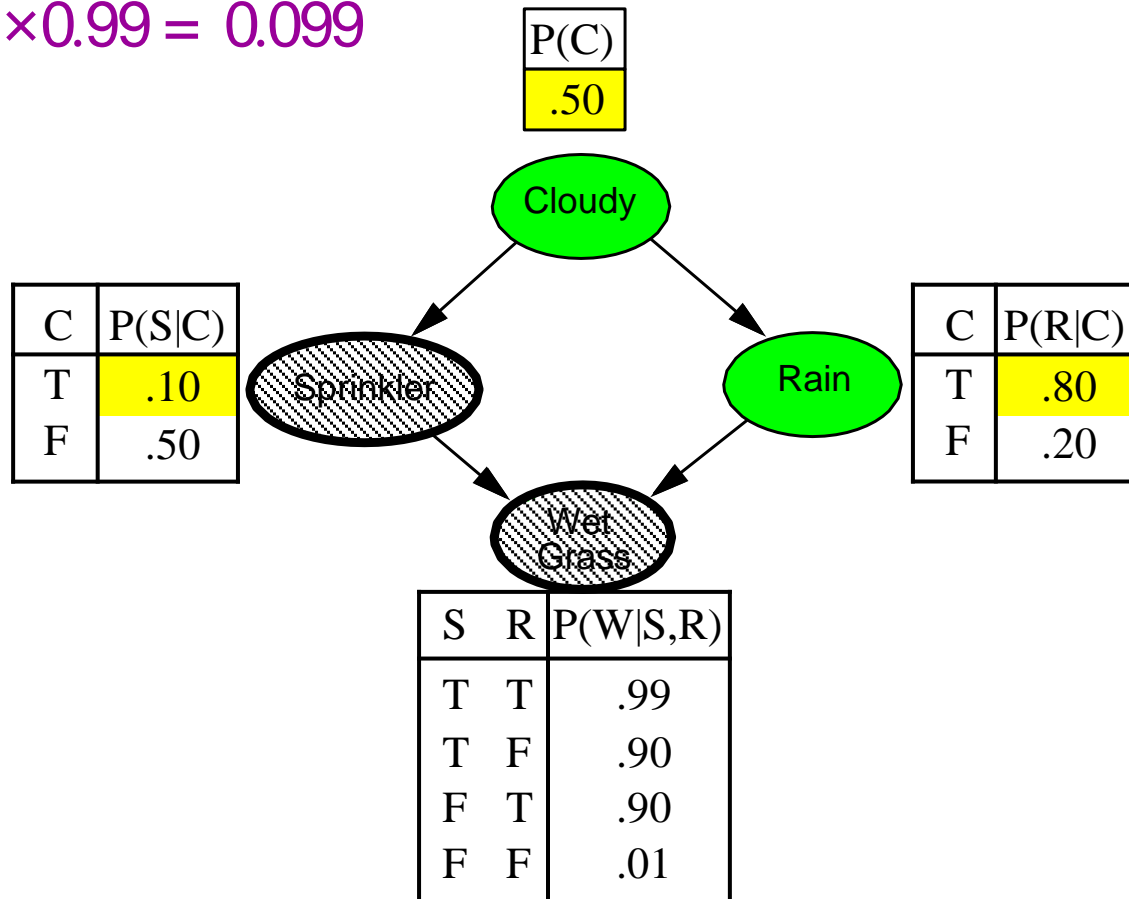
可能性权重的例子

- $w = 1.0 \times 0.1$



可能性权重的例子

- $w = 1.0 \times 0.1 \times 0.99 = 0.099$



可能性权重分析

- 加权样本的抽样概率为

$$S_{ws}(z,e) = \prod_{i=1}^l P(z_i | \text{parents}(Z))$$

- 注意：只注意祖先的证据

- 介于前后分布之间

- 对于每个给定的采样值 z , e 的权重是：


$$w(z,e) = \prod_{i=1}^m P(e_i | \text{parents}(E_i))$$

- 加权抽样概率为

$$S_{ws}(z,e) w(z,e) = \prod_{i=1}^l P(z_i | \text{parents}(Z)) \prod_{i=1}^m P(e_i | \text{parents}(E_i))$$

$= P(z, e)$ (通过网络的标准全局语义)

- 因此，可能性加权的估计值和实际值是一致的
- 但是，由于存在许多证据变量，性能仍然会下降
- 因为几个样品几乎占了全部 w 值



使用MCMC进行近似推理

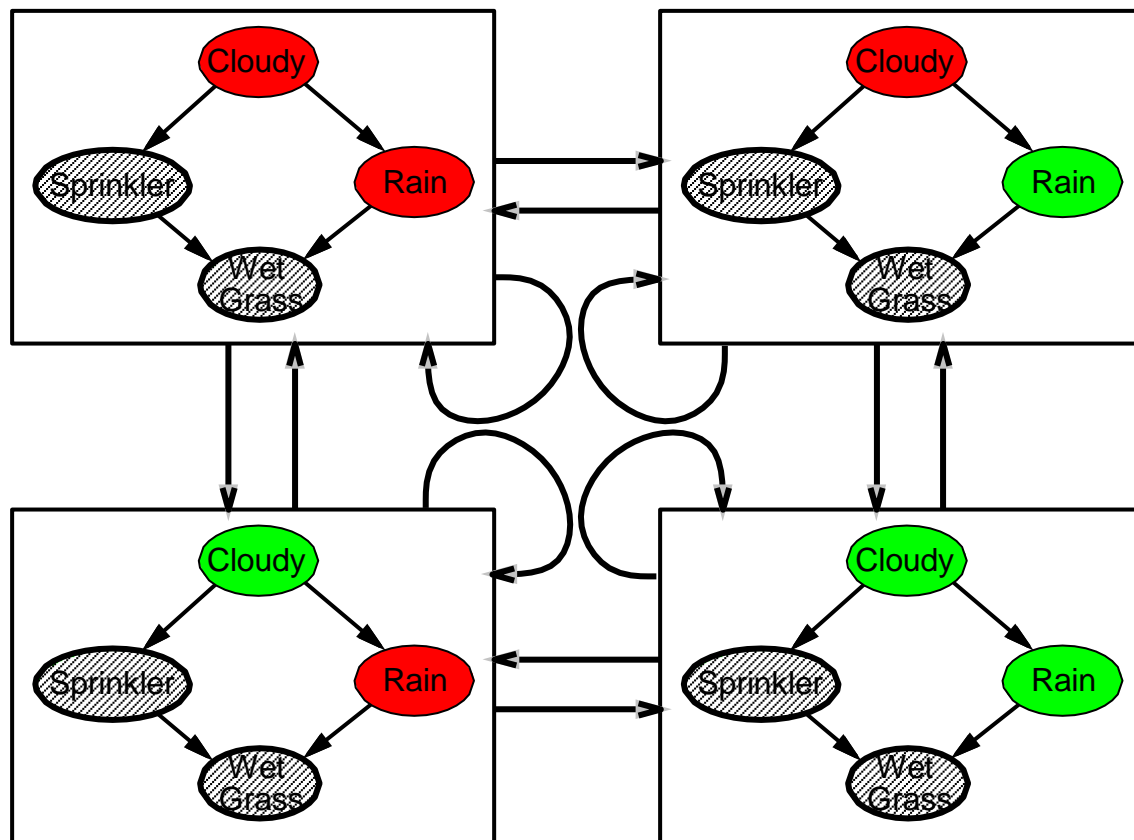
- 网络的“状态” = 当前对所有变量的赋值。
- 通过对一个给定的变量进行马尔科夫毯抽样个，依次对每个变量进行抽样，保持证据固定，从而生成下一状态

```
function MCMC-Ask( $X, e, bn, N$ ) returns an estimate of  $P(X|e)$ 
  local variables:  $N[X]$ , a vector of counts over  $X$ , initially zero
                    $Z$ , the nonevidence variables in  $bn$ 
                    $x$ , the current state of the network, initially copied from  $e$ 
  initialize  $x$  with random values for the variables in  $Y$ 
  for  $j = 1$  to  $N$  do
    for each  $Z_i$  in  $Z$  do
      sample the value of  $Z_i$  in  $x$  from  $P(Z_i | mb(Z_i))$ 
        given the values of  $MB(Z_i)$  in  $x$ 
       $N[x] \leftarrow N[x] + 1$  where  $x$  is the value of  $X$  in  $x$ 
  return Normalize( $N[X]$ )
```

- 每次还可以选择一个变量随机抽样

马尔科夫链

- 在 $Sprinkler = true, WetGrass = true$ 下，有四种状态



MCMC实例

- 估计 $P(Rain|Sprinkler = true, WetGrass = true)$
- 对 *Cloudy* 和 *Rain* 反复采样可以得到马尔科夫毯
- 之后在样本中统计 *Rain* 的实际次数
- 例如访问100 个地区
 - 31 个 $Rain = true$, 69 个 $Rain = false$

$$\begin{aligned} P(Rain|Sprinkler = true, WetGrass = true) \\ = \text{Normalize}((31, 69)) = (0.31, 0.69) \end{aligned}$$

- 定理：链趋于平稳分布
- 长期运行后，每个地区统计结果的比值将和后验概率接近

马尔科夫毯抽样

- 关于 *Cloudy* 的马尔科夫毯是 *Sprinkler* 和 *Rain*
- 关于 *Rain* 的马尔科夫毯是 *Cloudy*, *Sprinkler*, 和 *WetGrass*

- 马尔可夫毯的概率计算公式如下：

$$P(x'_i | mb(X_i)) = P(x'_i | parents(X_i)) \prod_{Z_j \in Children(X_i)} (z_j | parents(Z_j))$$

- 这种方法在并行传输系统下实现很容易
- 计算方面主要的问题有两个：
 - 难以判断计算是否完成
 - 如果马尔可夫毯很大，可能会造成浪费： $P(X_i | mb(X_i))$ 变化不大(大数定律)

小结

- 变量消除的精确推理：
 - 多重树 (polytrees) 上：多项式时间
 - 一般图上：NP-hard
 - 空间=时间，对拓扑结构非常敏感
- LW和MCMC的近似推理：
 - 当有大量(下游)证据时，LW表现不佳
 - LW, MCMC一般对拓扑结构不敏感
 - 收敛可能非常缓慢，概率接近1或0
 - 可以处理离散和连续变量的任意组合

